

Datenreduktion durch PCA-Netze

Praktikum Adaptive Systeme


Principal Component Analysis PCA

Zerlegung in orthogonale Eigenvektoren = Basisvektoren

„Hauptkomponentenanalyse“, „principal component analysis“, „Karhunen-Loève-Entwicklung“, „Hotelling-Transformation“, ...

Eigenvektoren – Wozu?

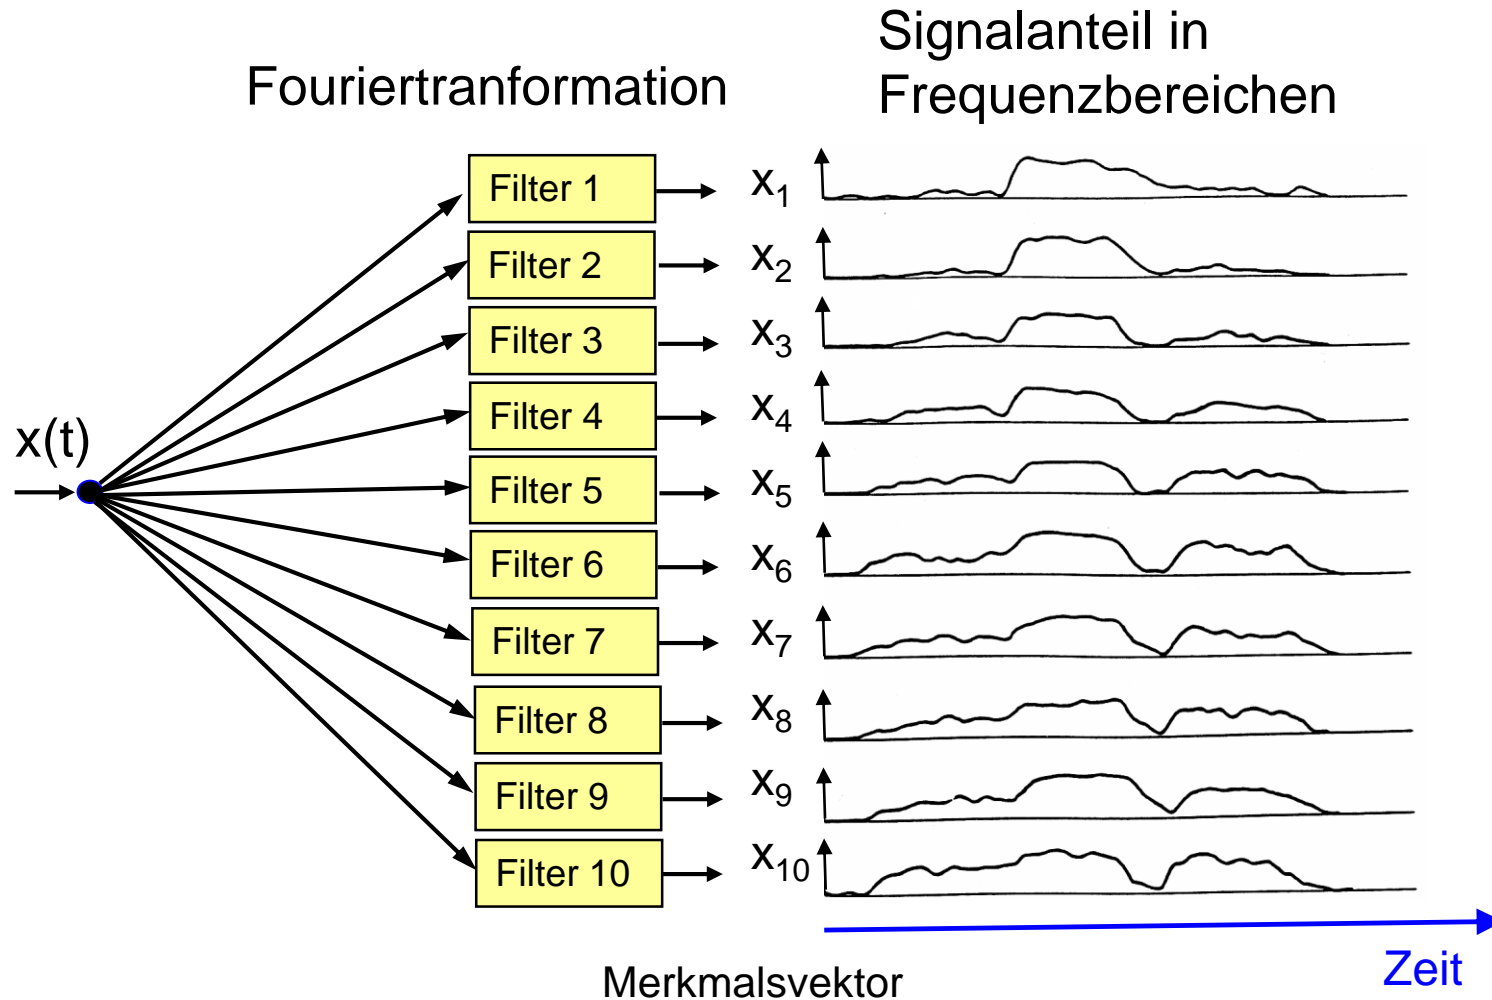
2



Merkmals-
transformation
auf
Hauptrichtungen

Transformation mit minimalem MSE


Beispiel: Sprachkodierung



Transformation mit minimalem MSE

Beispiel: Sprachkodierung mit n -dim Samples \mathbf{x} , hier: $n=2$


- **Transformation** (Rotation) des Koordinatensystems auf Hauptachsen
- **Vernachlässigung** der Anteile des 2. Kanals: Ersatz des zweiten Kanals durch ersten



Beispiel: Bildkodierung

Bildaufteilung

Zerteilen in Blöcke, jeder Block = Mustervektor



Principal Component Analysis (PCA)

Anwendungen – Datenkompression:

Vernachlässigen der Raumrichtungen mit kleiner Varianz (kleinem Eigenwert der Eigenvektoren)

Beispiel natürliche Bilder:

- Zerlege Bild in diskrete Blöcke aus 8x8 Pixel
- Fasse 8x8-Blöcke als Vektoren auf und berechne Eigenvektoren der Kovarianzmatrix
- Führe Rotation mit Matrix der Eigenvektoren aus und vernachlässige dabei Komponenten zu Eigenvektoren mit kleinem Eigenwert



Original



Rekonstruktion,
24 von 192 Koeffizienten




Rekonstruktion,
16 von 192 Koeffizienten



Eigenschaften natürlicher Bilder

Fehler beim Vernachlässigen höh. Komponenten

$n = 256 \times 256 = 65536$ Komponenten



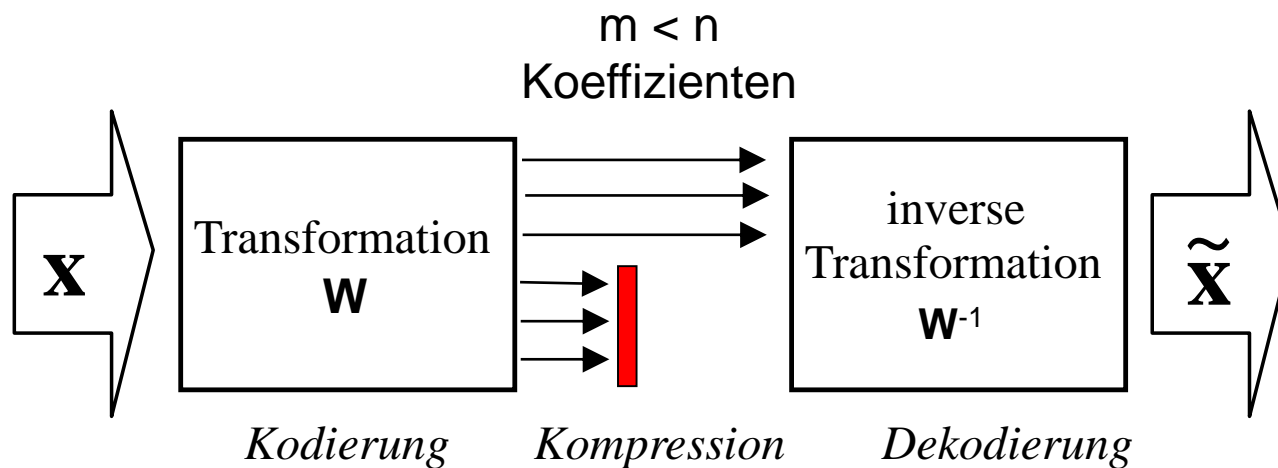
Beispiel: Bildkodierung (transform coding)

parallele Signale

Projektion auf wichtige Basisvektoren:

Wähle \mathbf{W} so, dass $\sigma_i^2 > \sigma_j^2$ bei $i < j$

Rückprojektion: durch inverse Matrix \mathbf{W}^{-1}



Sanger PCA-Netz


- **Vollständige Zerlegung von $\{\mathbf{x}\}$ in n Eigenvektoren (Gram-Schmidt) mit zentrierten Mustern**

$\{\mathbf{x}\}_0 = \{\mathbf{x}\}, i=1$ *initiale Menge aller zentrierten Muster*

1. Suche die Richtung größter Varianz in $\{\mathbf{x}\}_{i-1}$. Dies ist \mathbf{e}_i .
2. Ziehe diese Richtung (Dimension) von $\{\mathbf{x}\}_{i-1}$ ab. Wir erhalten $\{\mathbf{x}\}_i$.
3. Wenn $i < n$, setze $i := i+1$, gehe zu 1.

Diskret für stochastisches \mathbf{x} , \mathbf{w} :

Sanger-Netz



PCA Netze für geordnete Zerlegung

Sanger-Methode: *stochastischer* Algorithmus

Lernen: $\mathbf{w}_i(t) = \mathbf{w}_i(t-1) + \gamma(t) y_i \mathbf{x}_i$, $|\mathbf{w}_i(t)|=1$ "Generalisierte" Hebb-Regel

Musterreduktion (Ausdünnen des Eingaberaums)
Stufe 1

$$\mathbf{x}_2 := \mathbf{x}_1 - \mathbf{w}_1(t-1)y_1 \quad \mathbf{x}_2 \perp \mathbf{w}_1 \quad !!$$

...

Stufe k

$$\mathbf{x}_{k+1} := \mathbf{x}_k - \mathbf{w}_k(t-1)y_k \quad \text{und } \mathbf{x}_1 := \mathbf{x}, k = 1..i-1$$

Lernen Stufe k

$$\rightarrow \mathbf{w}_k(t) = \mathbf{w}_k(t-1) + \gamma(t) y_k \left(\mathbf{x}_k - \sum_{j=1}^{k-1} \mathbf{w}_j y_j \right)$$

stochastisches Lernen

PCA Netze für geordnete Zerlegung

Erwartungswert-Methode: **deterministischer** Algorithmus

Lernen: $\mathbf{w}_i(t) = \mathbf{w}_i(t-1) + \gamma(t) \langle \mathbf{x}_i \mathbf{x}_i^T \rangle \mathbf{w}_i(t-1)$, $|\mathbf{w}_i(t)|=1$
mit der Korrelationsmatrix $\langle \mathbf{x}_i \mathbf{x}_i^T \rangle = \mathbf{C}_{xx}$

Musterreduktion (Ausdünnen des Eingaberaums)

Stufe 1

$$\{\mathbf{x}\}_2 := \{\mathbf{x}\}_1 - \mathbf{w}_1 \{\mathbf{x}^T \mathbf{w}_1\}_1 \quad \{\mathbf{x}\}_2 \perp \mathbf{w}_1 \quad \text{!! und bilden von } \langle \mathbf{x}_i \mathbf{x}_i^T \rangle = \mathbf{C}_{xx}(2)$$

...

$\mathbf{x}_i \in \{\mathbf{x}\}_2$

Stufe k

$$\{\mathbf{x}\}_{k+1} := \{\mathbf{x}\}_k - \mathbf{w}_k \{\mathbf{y}\}_k \quad \text{und } x_1 := x, k = 1..i-1$$

Lernen Stufe k

$$\rightarrow \mathbf{w}_k(t) = \mathbf{w}_k(t-1) + \gamma(t) \langle \mathbf{x}_i \mathbf{x}_i^T \rangle \mathbf{w}_k(t-1), \quad |\mathbf{w}_k(t)|=1$$

Bilden der Korrelationsmatrix \mathbf{C}_{xx}

• Bilden des äußeren Produkts $\mathbf{x}\mathbf{x}^T$

$$\begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix} \begin{bmatrix} x_1 & \dots & x_n \end{bmatrix} = \begin{bmatrix} x_1 & \dots & 0 \\ \vdots & \ddots & 0 \\ x_n & \dots & 0 \end{bmatrix} \begin{bmatrix} x_1 & \dots & x_n \\ \vdots & \ddots & \vdots \\ 0 & 0 & 0 \end{bmatrix} = \begin{bmatrix} x_1 x_1 & \dots & x_1 x_n \\ \vdots & \ddots & \vdots \\ x_n x_1 & \dots & x_n x_n \end{bmatrix}$$

• Bilden des Erwartungswertes $\langle \mathbf{x}\mathbf{x}^T \rangle = \mathbf{C}_{xx}$

$$\langle \mathbf{x}\mathbf{x}^T \rangle = \frac{1}{m} \sum_{i=1}^m \mathbf{x}_i \mathbf{x}_i^T = \frac{1}{m} \begin{bmatrix} \sum_{i=1}^m x_1(i)x_1(i) & \dots & \sum_{i=1}^m x_1(i)x_n(i) \\ \vdots & \ddots & \vdots \\ \sum_{i=1}^m x_n(i)x_1(i) & \dots & \sum_{i=1}^m x_n(i)x_n(i) \end{bmatrix}$$

Fragen ?