




Multilayer-Perzeptrons (MLPs) und Backpropagation

Netzaufbau Perzeptron/Adaline




Perzeptron

$$\underline{x} \in \{0,1\}^n \quad L(\underline{x}) \in \{0,1\}^m \quad S(z) = \begin{cases} 1, & z > 0 \\ 0, & z \leq 0 \end{cases}$$

Adaline

$$\underline{x} \in \mathbb{R}^n \quad L(\underline{x}) \in \mathbb{R}^m \quad S(z) \text{ beliebig}$$

Netzaufbau Perzeptron/Adaline




Perzeptron

$$\underline{x} \in \{0,1\}^n \quad L(\underline{x}) \in \{0,1\}^m \quad S(z) = \begin{cases} 1, & z > 0 \\ 0, & z \leq 0 \end{cases}$$

Adaline

$$\underline{x} \in \mathbb{R}^n \quad L(\underline{x}) \in \mathbb{R}^m \quad S(z) \text{ beliebig}$$

Netzaufbau Perzeptron/Adaline



Perzeptron

$$\underline{x} \in \{0,1\}^n \quad L(\underline{x}) \in \{0,1\}^m \quad S(z) = \begin{cases} 1, & z > 0 \\ 0, & z \leq 0 \end{cases}$$


$$\text{Lernregel: } W \leftarrow W - \gamma \cdot \underline{x} \cdot (\underline{y} - L(\underline{x}))^T$$

Adaline

$$\underline{x} \in \mathbb{R}^n \quad L(\underline{x}) \in \mathbb{R}^m \quad S(z) \text{ beliebig}$$

$$\text{Lernregel: } W \leftarrow W - \gamma \cdot \frac{1}{\underline{x}^T \underline{x}} \cdot \underline{x} \cdot (W^T \underline{x} - L(\underline{x}))^T$$

Netzaufbau Perzeptron/Adaline



Perzeptron

$$\underline{x} \in \{0,1\}^n \quad L(\underline{x}) \in \{0,1\}^m \quad S(z) = \begin{cases} 1, & z > 0 \\ 0, & z \leq 0 \end{cases}$$


$$\text{Lernregel: } W \leftarrow W - \gamma \cdot \underline{x} \cdot \underline{\delta}^T \quad \underline{\delta} := \underline{y} - L(\underline{x})$$

Adaline

$$\underline{x} \in \mathbb{R}^n \quad L(\underline{x}) \in \mathbb{R}^m \quad S(z) \text{ beliebig}$$

$$\text{Lernregel: } W \leftarrow W - \gamma \cdot \frac{1}{\underline{x}^T \underline{x}} \cdot \underline{x} \cdot \underline{\delta}^T \quad \underline{\delta} := W^T \underline{x} - L(\underline{x})$$

Netzaufbau Perzeptron/Adaline



Perzeptron

$$\underline{x} \in \{0,1\}^n \quad L(\underline{x}) \in \{0,1\}^m \quad S(z) = \begin{cases} 1, & z > 0 \\ 0, & z \leq 0 \end{cases}$$

$$\text{Lernregel: } W \leftarrow W - \gamma \cdot \underline{x} \cdot \underline{\delta}^T \quad \underline{\delta} := \underline{y} - L(\underline{x})$$

Lernziel: Linear separierbare Mengen


Adaline

$$\underline{x} \in \mathbb{R}^n \quad L(\underline{x}) \in \mathbb{R}^m \quad S(z) \text{ beliebig}$$

$$\text{Lernregel: } W \leftarrow W - \gamma \cdot \frac{1}{\underline{x}^T \underline{x}} \cdot \underline{x} \cdot \underline{\delta}^T \quad \underline{\delta} := W^T \underline{x} - L(\underline{x})$$

Lernziel: Beliebige Lineare Transformationen
($S(z) = z$)

Netzaufbau Perzeptron/Adaline



Perzeptron

$$\underline{x} \in \{0,1\}^n \quad L(\underline{x}) \in \{0,1\}^m \quad S(z) = \begin{cases} 1, & z > 0 \\ 0, & z \leq 0 \end{cases}$$

$$\text{Lernregel: } W \leftarrow W - \gamma \cdot x \cdot \underline{\delta}^T \quad \underline{\delta} := \underline{y} - L(\underline{x})$$

Lernziel: Linear separierbare Mengen

Adaline


$$\underline{x} \in \mathbb{R}^n \quad L(\underline{x}) \in \mathbb{R}^m \quad S(z) \text{ beliebig}$$

$$\text{Lernregel: } W \leftarrow W - \gamma \cdot \frac{1}{\underline{x}^T \underline{x}} \cdot x \cdot \underline{\delta}^T \quad \delta := W^T \underline{x} - L(\underline{x})$$

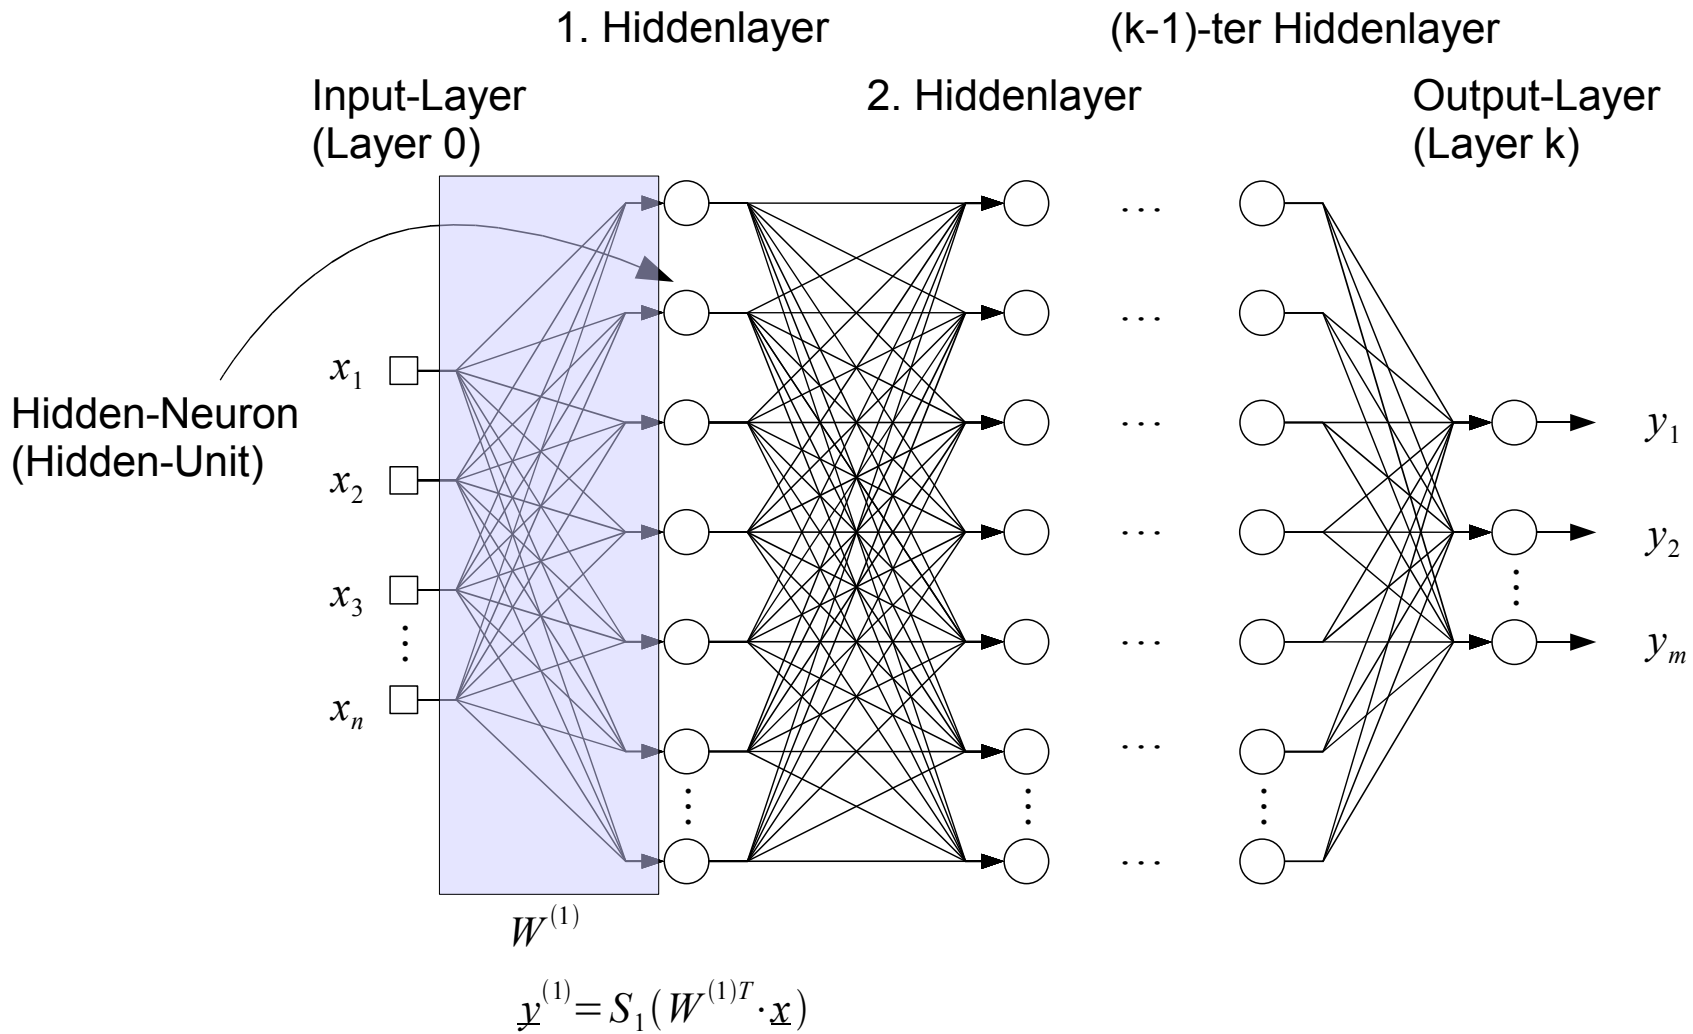
Lernziel: Beliebige Lineare Transformationen
($S(z) = z$)

Wie können komplexere Probleme gelöst werden?


Multilayer-Perzeptrons



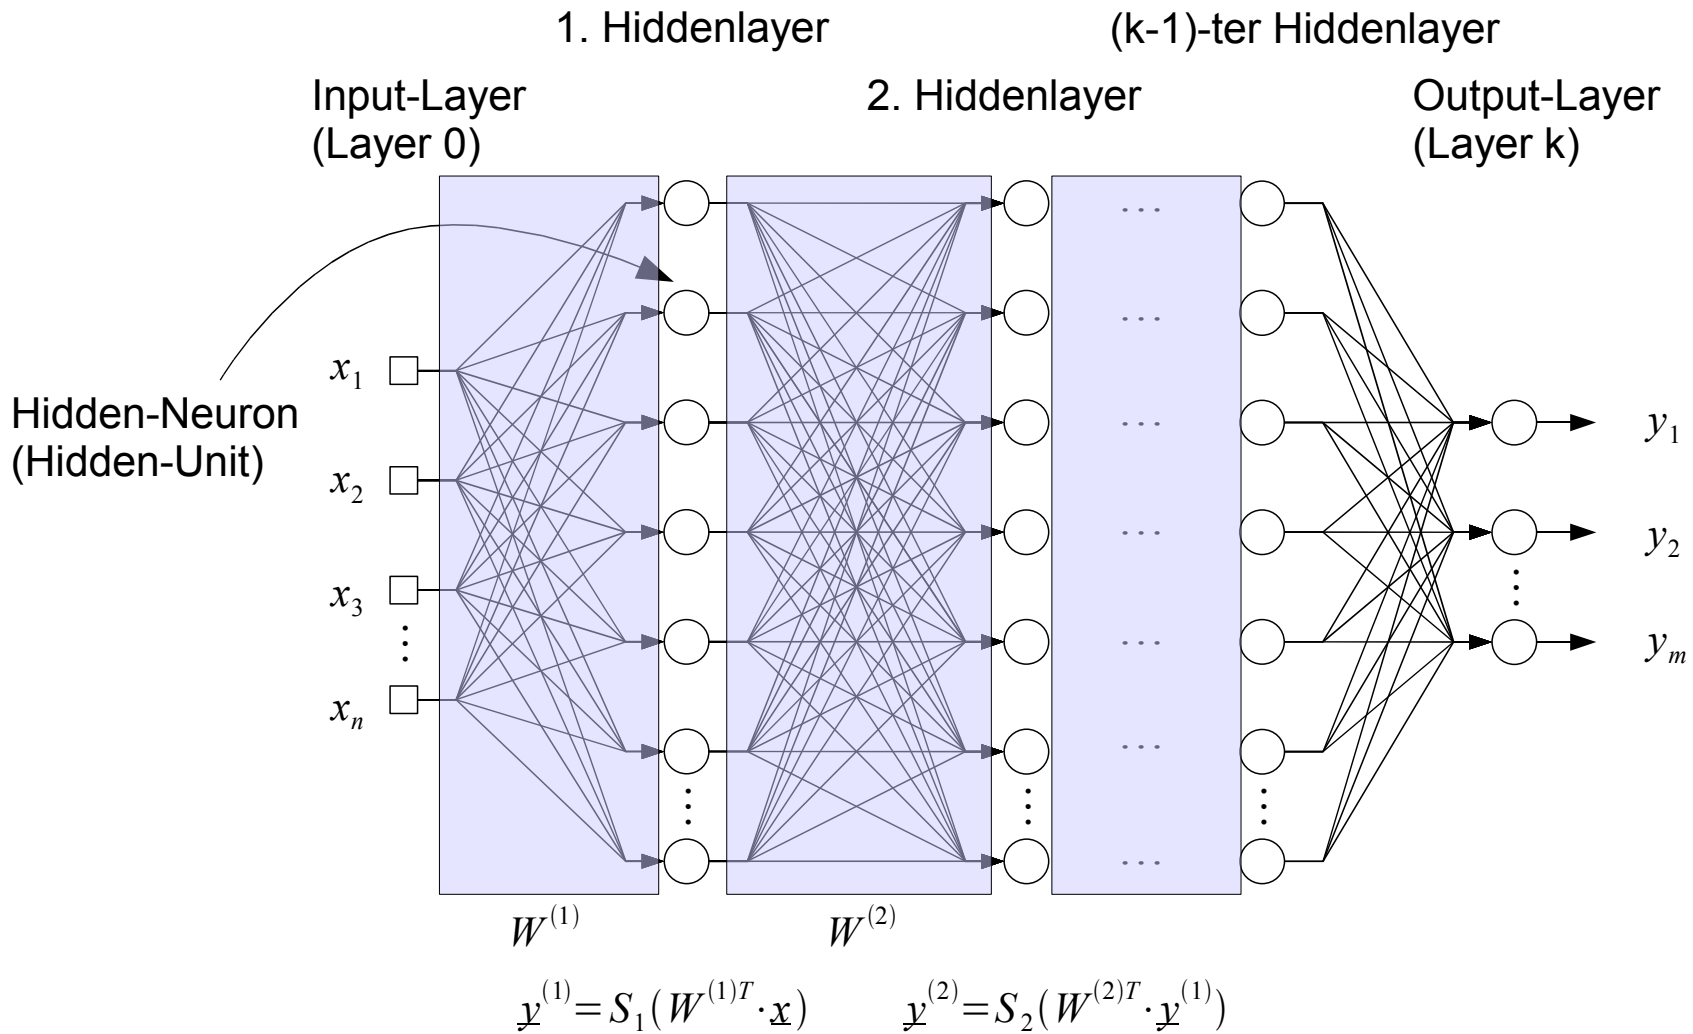
Multilayer-Perzeptrons




Multilayer-Perzeptrons



Multilayer-Perzeptrons




Multilayer-Perzeptrons




Backpropagation

forward pass
(Ausgabe berechnen)



Backpropagation


forward pass
(Ausgabe berechnen)



backward pass
(Fehlerrückführung)

Backpropagation

forward pass
(Ausgabe berechnen)



backward pass
(Fehlerrückführung)

Gewichtsanpassung durch: $\underline{w}_i^{(j)} \leftarrow \underline{w}_i^{(j)} - \gamma \cdot \underline{y}^{(j-1)} \cdot \delta_i^{(j)} \cdot S' (z_i^{(j)})$

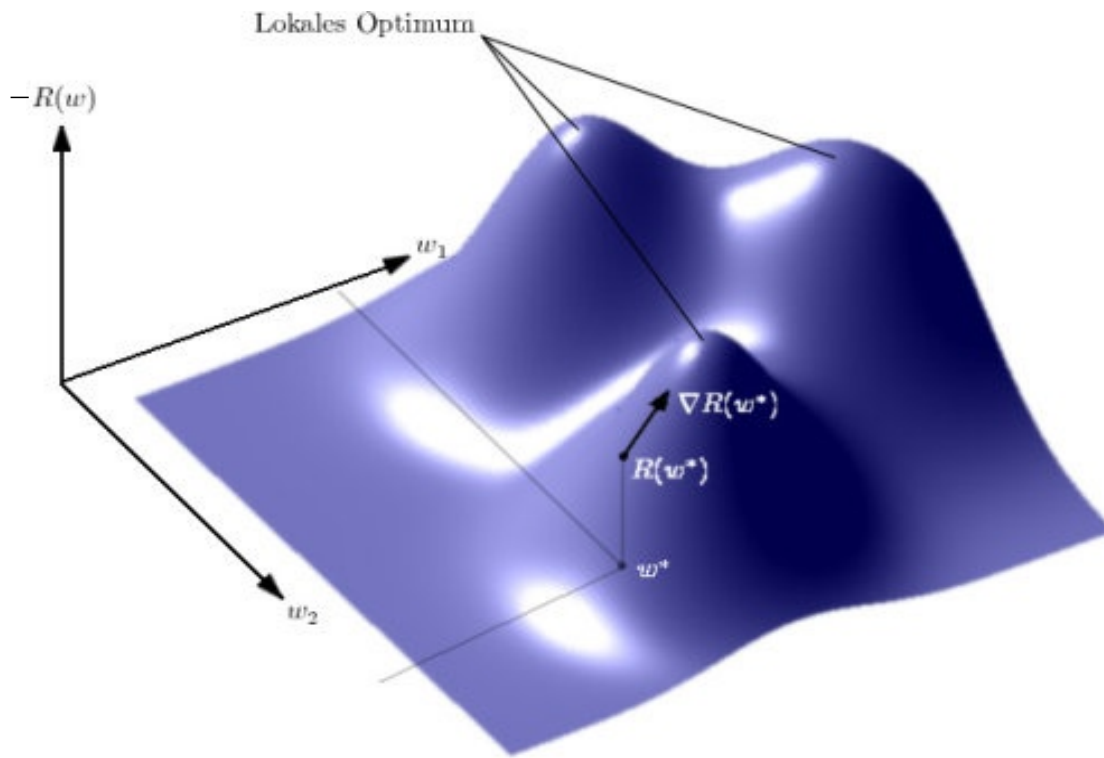
Backpropagation

Interpretation als Gradientenverfahren

Ziel: Minimierung der Fehlerfunktion

$$R(W^{(1)}, W^{(2)}, \dots, W^{(k)}) = \left\langle \left\| \underline{\delta}^{(k)} \right\|_2^2 \right\rangle_{\underline{x}}$$

(Erwartetes Längenquadrat des Fehlervektors)



Offline(Batch-) Variante

$$\underline{w}_i^{(j)} \leftarrow \underline{w}_i^{(j)} - \gamma \cdot \left\langle \underline{y}^{(j-1)} \cdot \delta_i^{(j)} \cdot S'_j(z_i^{(j)}) \right\rangle_{\underline{x}}$$

Online-Variante


$$\underline{w}_i^{(j)} \leftarrow \underline{w}_i^{(j)} - \gamma \cdot \underline{y}^{(j-1)} \cdot \delta_i^{(j)} \cdot S'_j(z_i^{(j)})$$

Snoope (**S**ystem for **N**uclear **O**nline **O**bservation of **P**otential **E**xplosives, 1989)

Entdeckung von Plastiksprengstoff im Fluggepäck

Eingabe: Gepäckstück

Ausgabe: Diagnose „gefährlich“ oder „ungefährlich“




Training und Test eines Backpropagation Netzwerks mit Gepäckstücken

Snoope (System for Nuclear Online Observation of Potential Explosives, 1989)

Entdeckung von Plastiksprengstoff im Fluggepäck

Eingabe: Gepäckstück

Ausgabe: Diagnose „gefährlich“ oder „ungefährlich“



Training und Test eines Backpropagation Netzwerks mit Gepäckstücken

Nettalk (Sejnowsky, Rosenberg, 1986)

Umwandlung von Text in Sprache


16 CPU-Stunden Backpropagation-Training für 98% Genauigkeit

Snoope (System for Nuclear Online Observation of Potential Explosives, 1989)

Entdeckung von Plastiksprengstoff im Fluggepäck

Eingabe: Gepäckstück

Ausgabe: Diagnose „gefährlich“ oder „ungefährlich“



Training und Test eines Backpropagation Netzwerks mit Gepäckstücken

Nettalk (Sejnowsky, Rosenberg, 1986)

Umwandlung von Text in Sprache

16 CPU-Stunden Backpropagation-Training für 98% Genauigkeit

Älteres System: DECTalk

Ausgabe Text->Sprache der Firma Digital Eq. (DEC)

Aufwand 20 PJ für 95% Genauigkeit

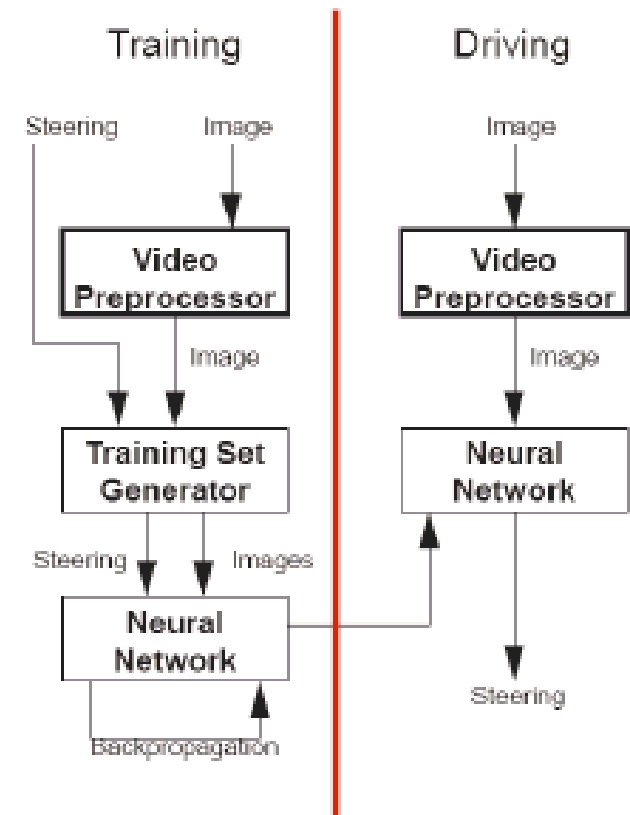
ALVINN (Autonomous Land Vehicle in a Neural Network)

Team: Carnegie-Mellon University, Pittsburgh USA

Methode: 2-Schicht Backpropagation

Training auf stationärem Supercomputer (100 MFlops)
mit Aufzeichnungen von 1200 simulierten Straßenbildern
(40x präsentiert)

Resultat: Automatisches Fahren auf Uni-Gelände
mit ca. 5 km/h, ausgelegt bis max. ca. 100 km/h



Multilayer-Perzeptrons

Was können Multilayer-Perzeptrons?

Folgendes ist bekannt:

Was können Multilayer-Perzeptrons?

Folgendes ist bekannt:

- Jede boolesche Funktion kann exakt durch ein Multilayer-Perzeptron mit 1 Hiddenlayer dargestellt werden.

Was können Multilayer-Perzeptrons?

Folgendes ist bekannt:

- Jede boolesche Funktion kann exakt durch ein Multilayer-Perzeptron mit 1 Hiddenlayer dargestellt werden.
- Jede beschränkte kontinuierliche Funktion kann beliebig genau durch ein MLP mit 1 Hiddenlayer und linearer Ausgabefunktionen im Ausgabelayer approximiert werden.

Was können Multilayer-Perzeptrons?

Folgendes ist bekannt:

- Jede boolesche Funktion kann exakt durch ein Multilayer-Perzeptron mit 1 Hiddenlayer dargestellt werden.
- Jede beschränkte kontinuierliche Funktion kann beliebig genau durch ein MLP mit 1 Hiddenlayer und linearer Ausgabefunktionen im Ausgabelayer approximiert werden.
- Jede beliebige Funktion kann beliebig genau durch ein MLP mit 2 Hiddenlayern und linearer Ausgabefunktion im Ausgabelayer approximiert werden.

Was können Multilayer-Perzeptrons?

Folgendes ist bekannt:

- Jede boolesche Funktion kann exakt durch ein Multilayer-Perzeptron mit 1 Hiddenlayer dargestellt werden.
- Jede beschränkte kontinuierliche Funktion kann beliebig genau durch ein MLP mit 1 Hiddenlayer und linearer Ausgabefunktionen im Ausgabelayer approximiert werden.
- Jede beliebige Funktion kann beliebig genau durch ein MLP mit 2 Hiddenlayern und linearer Ausgabefunktion im Ausgabelayer approximiert werden.
- Fazit: 1 Hiddenlayer in den meisten Fällen ausreichend