

Backpropagation – Beispiel R.Brause,

Zur Veranschaulichung des Ablaufs beim Backpropagation-Algorithmus sei hier ein konkretes Beispiel gerechnet. Angenommen, wir haben eine Netzwerkarchitektur wie sie in Abbildung 1 gezeigt ist.




Abb. 1 Eine 8x3x8-Architektur

Errechnen der Ausgabe

Die 8-dimensionale Eingabe $\mathbf{x} = (x_1, \dots, x_8)$ wird ergänzt durch die feste Bias-Eingabe 1, so dass $\mathbf{x} = (1, x_1, \dots, x_8)$ wird. Seien anfangs $x_1 = 0.1$, $x_2 = 0.2$, ..., $x_8 = 0.8$ und die Gewichte der ersten Schicht für jedes Neuron mit $w_0 = 0$, $w_1 = 1$, ..., $w_8 = 1$ vorinitialisiert. Dann ergibt sich die Ausgabe für das erste Neuron der ersten Schicht mit $S(z)$ als Fermi-Funktion zu

$$z_1^{(1)} = \sum_{i=0}^8 w_{1i}^{(1)} x_i^{(1)} = w_0 + w_1 x_1 + \dots + w_8 x_8 = 0 + 0.1 + \dots + 0.8 = 3.6, \quad S(3.6) = 0.97 \quad (1)$$

für jedes der 3 Neuronen, so dass $\mathbf{y}^{(1)} = (1, 0.97, 0.97, 0.97)$ die um die Bias-Aktivität 1 ergänzte Eingabe für die nächste Schicht darstellt. Auch hier seien die Gewichte vorinitialisiert, und zwar alle gleichmäßig mit $w_{ij}^{(2)} = 1$. Somit ist die Aktivität für das erste Neuron der zweiten Schicht

$$y_1^{(2)} = \sum_{j=0}^3 w_{1j}^{(2)} x_j^{(1)} = w_0^{(2)} + w_1^{(2)} x_1^{(1)} + w_2^{(2)} x_2^{(1)} + w_3^{(2)} x_3^{(1)} = 1 + 0.97 + 0.97 + 0.97 = 3.91 \quad (2)$$

Gleiches gilt für alle anderen Neuronen, so dass für $\mathbf{y}^{(2)} = (3.91, 3.91, \dots, 3.91)$ ein 8-dim Ausgabevektor errechnet ist.

Fehlerrückführung

Angenommen, die 8-dim. Lehrervorgabe sei $\mathbf{L} = (1, 0, \dots, 0)$. Da die Ausgabe in dieser Hinsicht zu groß ist, müssen also überall im Netz die Gewichte verkleinert werden, um der Lehrervorgabe zu genügen. Der Fehler der zweiten Schicht ist dann

$$\begin{aligned} \delta^{(2)} &= - ((y_1^{(2)} - L_1) S'(z_1^{(2)}), \dots, (y_8^{(2)} - L_8) S'(z_8^{(2)})) = - ((y_1^{(2)} - L_1), \dots, (y_8^{(2)} - L_8)) \\ &= - (2.91, 3.91, \dots, 3.91) \quad \text{da hier } S(z) = z \text{ und damit } S'(z) = 1 \end{aligned} \quad (3)$$

Für die erste Schicht errechnet sich der Fehler für das i -te Neuron ($i = 1, 2, 3$) zu

$$\delta_i^{(1)} = \left(\sum_{j=1}^8 \delta_j^{(2)} w_{ji}^{(2)} \right) S'(z_i^{(1)}) \quad (4)$$

Hier wird von dem Fehler am j -ten Neuron, der an der 2. Schicht festgestellt wurde, über die 8 Gewichte, über die Neuron i mit den 8 Ausgabeneuronen verbunden ist, auf eine falsche Ausgabe von Neuron i zurückgerechnet.

Konkret errechnet sich der Fehler mit

$$\left(\sum_{j=1}^8 \delta_j^{(2)} w_{ji}^{(2)} \right) = - (2.91 \cdot 1 + 3.91 \cdot 1 + \dots + 3.91 \cdot 1) = -30.28 \quad (5)$$

zu

$$\begin{aligned} \delta_1^{(1)} &= \left(\sum_{j=1}^8 \delta_j^{(2)} w_{j1}^{(2)} \right) S'(z_1^{(1)}) = -30.28 \cdot (1-S(z_1))S(z_1) = -30.28 \cdot (1-S(3.6))S(3.6) \\ &= -30.28 \cdot (1-0.97) \cdot 0.97 = -30.28 \cdot (0.03) \cdot 0.97 = -0.88 \end{aligned}$$

$$\delta_2^{(1)} = \left(\sum_{j=1}^8 \delta_j^{(2)} w_{j2}^{(2)} \right) S'(z_2^{(1)}) = -30.28 \cdot (1-S(z_2))S(z_2) = -0.88 \quad (6)$$

$$\delta_3^{(1)} = \left(\sum_{j=1}^8 \delta_j^{(2)} w_{j3}^{(2)} \right) S'(z_3^{(1)}) = -30.28 \cdot (1-S(z_3))S(z_3) = -0.88$$

Verbessern der Gewichte

Sodann wird für die Änderung der Gewichte

$$w_{ij}(t+1) = w_{ij}(t) + \Delta w_{ij}(t) \quad (7)$$

die Verbesserungen errechnet mit

$$\Delta w_{ij}(t) = \gamma \cdot \delta_i(t) \cdot x_j(t) \quad (8)$$

Für die Gewichte der zweiten Schicht mit $S(z) = z$ gilt

$$\Delta w_{ij}^{(2)}(t) = \gamma \delta_i^{(2)} x_j^{(2)} = -\gamma (y_i^{(2)} - L_i) x_j^{(2)} \quad (9)$$

und somit für das 1. Neuron

$$\Delta w_{10}^{(2)}(t) = -\gamma (y_1^{(2)} - L_1) x_0^{(2)} = -\gamma \cdot 2.91 \cdot 1 \quad \text{Bias-Gewicht} \quad (10)$$

$$\Delta w_{11}^{(2)}(t) = -\gamma (y_1^{(2)} - L_1) x_1^{(2)} = -\gamma \cdot 2.91 \cdot 0.97$$

$$\Delta w_{12}^{(2)}(t) = -\gamma (y_1^{(2)} - L_1) x_2^{(2)} = -\gamma \cdot 2.91 \cdot 0.97$$

$$\Delta w_{13}^{(2)}(t) = -\gamma (y_1^{(2)} - L_1) x_3^{(2)} = -\gamma \cdot 2.91 \cdot 0.97$$

und für das 2. Neuron

$$\Delta w_{20}^{(2)}(t) = -\gamma (y_2^{(2)} - L_2) x_0^{(2)} = -\gamma \cdot 3.91 \cdot 1 \quad \text{Bias-Gewicht} \quad (11)$$

$$\Delta w_{21}^{(2)}(t) = -\gamma (y_2^{(2)} - L_2) x_1^{(2)} = -\gamma \cdot 3.91 \cdot 0.97$$

$$\Delta w_{22}^{(2)}(t) = -\gamma (y_2^{(2)} - L_2) x_2^{(2)} = -\gamma \cdot 3.91 \cdot 0.97$$

$$\Delta w_{23}^{(2)}(t) = -\gamma (y_2^{(2)} - L_2) x_3^{(2)} = -\gamma \cdot 3.91 \cdot 0.97$$

bis zum 8. Neuron

$$\Delta w_{80}^{(2)}(t) = -\gamma (y_8^{(2)} - L_8) x_0^{(2)} = -\gamma \cdot 3.91 \cdot 1 \quad \text{Bias-Gewicht} \quad (12)$$

$$\Delta w_{81}^{(2)}(t) = -\gamma (y_8^{(2)} - L_8) x_1^{(2)} = -\gamma \cdot 3.91 \cdot 0.97$$

$$\Delta w_{82}^{(2)}(t) = -\gamma (y_8^{(2)} - L_8) x_2^{(2)} = -\gamma \cdot 3.91 \cdot 0.97$$

$$\Delta w_{83}^{(2)}(t) = -\gamma (y_8^{(2)} - L_8) x_3^{(2)} = -\gamma \cdot 3.91 \cdot 0.97$$

Für die Gewichte der ersten Schicht ist mit Gl.(4) für das Gewicht der k -ten Eingabe zum i -ten Neuron

$$\Delta w_{ik}^{(1)}(t) = \gamma \delta_i^{(1)} x_k^{(1)} = \gamma \left(\sum_{j=1}^8 \delta_j^{(2)} w_{ji}^{(2)} \right) S'(z_i^{(1)}) x_k^{(1)} \quad (13)$$

und damit für das 1. Neuron

$$\begin{aligned} \Delta w_{10}^{(1)}(t) &= \gamma \delta_1^{(1)} x_0^{(1)} = \gamma \left(\sum_{j=1}^8 \delta_j^{(2)} w_{j1}^{(2)} \right) S'(z_1^{(1)}) x_0^{(1)} & \text{Bias-Gewicht} & (14) \\ &= -\gamma \cdot 30.28 \cdot (1-0.97) \cdot 0.97 \cdot 1 = -\gamma \cdot 0.88 \end{aligned}$$

$$\begin{aligned} \Delta w_{11}^{(1)}(t) &= \gamma \delta_1^{(1)} x_1^{(1)} = \gamma \left(\sum_{j=1}^8 \delta_j^{(2)} w_{j1}^{(2)} \right) S'(z_1^{(1)}) x_1^{(1)} \\ &= -\gamma \cdot 30.28 \cdot (1-0.97) \cdot 0.97 \cdot 0.1 = -\gamma \cdot 0.088 \end{aligned}$$

...

$$\begin{aligned} \Delta w_{18}^{(1)}(t) &= \gamma \delta_1^{(1)} x_8^{(1)} = \gamma \left(\sum_{j=1}^8 \delta_j^{(2)} w_{j1}^{(2)} \right) S'(z_1^{(1)}) x_8^{(1)} \\ &= -\gamma \cdot 30.28 \cdot (1-0.97) \cdot 0.97 \cdot 0.8 = -\gamma \cdot 0.7 \end{aligned}$$

Für das 3. Neuron ist dies dann auch

$$\begin{aligned} \Delta w_{30}^{(1)}(t) &= \gamma \delta_3^{(1)} x_0^{(1)} = \gamma \left(\sum_{j=1}^8 \delta_j^{(2)} w_{j3}^{(2)} \right) S'(z_3^{(1)}) x_0^{(1)} & \text{Bias-Gewicht} & (15) \\ &= -\gamma \cdot 30.28 \cdot (1-0.97) \cdot 0.97 \cdot 1 = -\gamma \cdot 0.88 \end{aligned}$$

$$\begin{aligned} \Delta w_{31}^{(1)}(t) &= \gamma \delta_3^{(1)} x_1^{(1)} = \gamma \left(\sum_{j=1}^8 \delta_j^{(2)} w_{j3}^{(2)} \right) S'(z_3^{(1)}) x_1^{(1)} \\ &= -\gamma \cdot 30.28 \cdot (1-0.97) \cdot 0.97 \cdot 0.1 = -\gamma \cdot 0.088 \end{aligned}$$

...

$$\begin{aligned} \Delta w_{38}^{(1)}(t) &= \gamma \delta_3^{(1)} x_8^{(1)} = \gamma \left(\sum_{j=1}^8 \delta_j^{(2)} w_{j3}^{(2)} \right) S'(z_3^{(1)}) x_8^{(1)} \\ &= -\gamma \cdot 30.28 \cdot (1-0.97) \cdot 0.97 \cdot 0.8 = -\gamma \cdot 0.7 \end{aligned}$$

Für die eigentliche Korrektur der Gewichte müssen wir unterscheiden: Beim *offline*-Learning werden die Verbesserungen $\Delta w_{ij}(t)$ über alle Muster $\mathbf{x}(t)$ (alle T Zeitpunkte t) gesammelt (addiert)

$$\Delta w_{ij} = \gamma \frac{1}{T} \sum_{t=1}^T \Delta w_{ij}(t) \quad (16)$$

und dann erst tatsächlich umgesetzt; beim *online*-Learning dagegen sofort nach jedem Muster.